

Ecole Marocaine des Sciences de l'Ingénieur

Analyse Relationnelle du Football

Projet académique
Module : Bases de données NoSQL et Big Data

Réalisé par :
Taha El Arfaoui
KIMATH Elmer
Anas Chbira
Encadré par : Fatima Ezzahra MDARBI
Année universitaire : 2025–2026

0.1 Introduction

Le football moderne n'est plus question de simples matchs mais il repose de plus en plus sur l'exploitation et l'analyse des données afin d'évaluer avec précision les performances des joueurs, des équipes et des compétitions. Les données footballistiques sont à la fois volumineuses, hétérogènes et fortement interconnectées, ce qui rend leur stockage et leur analyse particulièrement complexes lorsqu'ils sont réalisés à l'aide des systèmes de gestion de bases de données relationnelles classiques.

Face à ces limites, les bases de données NoSQL, et plus particulièrement les bases orientées graphe, constituent une alternative particulièrement adaptée. Elles permettent de modéliser naturellement les relations entre les différentes entités du football :joueurs, clubs, matchs, ligues et compétitions et facilitent la réalisation d'analyses relationnelles complexes, tout en offrant une meilleure flexibilité et de meilleures performances.

Dans ce contexte, la base de données orientée graphe Neo4j a été retenue comme technologie centrale de ce projet. Neo4j offre un modèle de données intuitif basé sur des nœuds et des relations, ainsi qu'un langage de requête dédié, Cypher, spécialement conçu pour l'exploration et l'analyse des graphes. Ce choix permet de représenter fidèlement la structure du football moderne et d'exécuter efficacement des requêtes analytiques avancées portant sur les relations entre les différentes entités.

Ainsi, ce projet a pour objectif de concevoir une base de données NoSQL orientée graphe sous Neo4j dédiée à l'analyse footballistique, d'implémenter un modèle de données cohérent et représentatif de la réalité du football professionnel, et de développer une application analytique permettant l'exploration, la visualisation et l'analyse avancée des données à travers une interface web interactive.

Chapitre 1

Analyse des besoins et objectifs

1.1 Analyse des besoins

Les données footballistiques étudiées dans ce projet couvrent un large ensemble d'entités, notamment les ligues, les compétitions, les clubs, les joueurs, les matchs ainsi que des statistiques avancées issues d'une saison complète. Ces données sont caractérisées par un fort degré d'interconnexion : un joueur appartient à un club, un club participe à une ligue et à des compétitions, et chaque match met en relation plusieurs équipes dans un contexte précis.

Cette richesse relationnelle rend l'exploitation des données complexe lorsqu'elle est réalisée à l'aide de modèles relationnels classiques, souvent limités par la multiplication des jointures . Il est donc nécessaire de disposer d'un modèle de données flexible, capable de représenter efficacement ces relations tout en permettant des analyses performantes.

Le système à concevoir doit ainsi répondre aux besoins suivants :

— représenter de manière explicite et cohérente les relations entre les différentes entités footballistiques ;
— analyser les performances individuelles des joueurs ainsi que les performances collectives des clubs et des ligues ;
— exécuter des requêtes analytiques complexes portant sur les statistiques et les relations entre entités ;

1.2 Objectifs du projet

L'objectif principal de ce projet est de démontrer l'apport des bases de données NoSQL orientées graphe dans l'analyse de données sportives complexes. Pour atteindre cet objectif, plusieurs objectifs spécifiques ont été définis :

— concevoir une base de données NoSQL orientée graphe, adaptée aux spécificités du domaine footballistique ;
— modéliser les entités clés du football professionnel ainsi que leurs relations (joueurs, clubs, matchs, ligues, compétitions et statistiques) ;
— permettre la réalisation d'analyses statistiques avancées à partir des données stockées dans le graphe ;
— développer une application analytique permettant l'exploration, la visualisation et la comparaison des données à travers une interface web interactive ;

Chapitre 2

Choix technologiques

2.1 Choix du modèle NoSQL

Le choix d'un modèle NoSQL orienté graphe s'explique par la nature même des données footballistiques, qui sont fortement interconnectées et évolutives. Dans le domaine du football, les relations entre les entités joueurs, clubs, matchs, ligues et compétitions jouent un rôle central et portent autant d'information que les entités elles-mêmes.

Contrairement aux bases de données relationnelles, où les relations sont implémentées à l'aide de clés étrangères et de jointures coûteuses, le modèle graphe considère les relations comme des éléments de première classe.

Le modèle orienté graphe est ainsi particulièrement adapté aux analyses relationnelles complexes, telles que la comparaison de joueurs appartenant à différents clubs, l'analyse des performances par ligue ou par compétition, ou encore l'exploration des parcours et interactions entre les entités footballistiques.

2.2 Choix de la base de données

Parmi les systèmes de gestion de bases de données orientées graphe existants, **Neo4j** a été retenu comme solution centrale pour ce projet. Neo4j est l'une des bases de données graphe les plus matures et les plus largement utilisées, offrant un environnement robuste et performant pour l'analyse de graphes complexes.

Neo4j repose sur un modèle de données intuitif basé sur des nœuds, des relations et des propriétés, permettant une représentation fidèle des structures relationnelles du football. Il propose également le langage de requête **Cypher**, spécifiquement conçu pour l'exploration et l'analyse de graphes, offrant une syntaxe lisible et expressive.

Les principaux avantages de Neo4j dans le cadre de ce projet sont :

- l'utilisation du langage de requête Cypher, facilitant l'écriture et la compréhension des requêtes analytiques ;
- de bonnes performances pour les graphes de grande taille et à forte densité relationnelle ;
- une prise en charge des relations, évitant les jointures complexes ;
- une intégration simple avec des langages et frameworks modernes tels que Python et JavaScript.

2.3 Langages et outils

La réalisation de ce projet s'appuie sur un ensemble de langages et d'outils complémentaires, chacun jouant un rôle précis dans l'architecture globale de l'application :

- **Cypher** : langage de requête utilisé pour interroger la base Neo4j, créer les nœuds et relations, et réaliser les analyses statistiques et relationnelles ;
- **Python / FastAPI** : utilisé pour le développement du backend applicatif, assurant la communication avec Neo4j, l'exécution des requêtes Cypher et l'exposition des données via des API REST ;
- **JavaScript** : employé pour le développement du frontend, permettant l'affichage dynamique des données et l'interaction avec les services backend ;
- **Neo4j Browser** : outil de visualisation et d'exploration du graphe, utilisé pour la validation du modèle de données et l'analyse visuelle des relations.

Chapitre 3

Modélisation de la base de données

3.1 Entités principales

Le modèle de données orienté graphe repose sur un ensemble d'entités représentant les éléments fondamentaux du football professionnel. Chaque entité correspond à un nœud du graphe et porte des propriétés spécifiques décrivant ses caractéristiques.

Les entités principales sont les suivantes :

— **League** : représente un championnat national (Premier League, La Liga, Serie A, etc.). Cette entité permet de regrouper les clubs et les matchs disputés dans un même championnat.

— **Compétition** : représente une compétition nationale ou internationale, telle que la Champions League ou l'Europa League. Un club peut participer à plusieurs compétitions au cours d'une saison.

— **Club** : représente une équipe de football professionnelle. Le club constitue une entité centrale du modèle, reliant les joueurs, les ligues, les compétitions et les matchs.

— **Player** : représente un joueur de football. Chaque joueur est associé à un club et possède des caractéristiques individuelles telles que l'âge, la nationalité et le poste.

— **PlayerStats** : regroupe les statistiques avancées d'un joueur pour une saison donnée (buts, passes décisives, minutes jouées, actions défensives, etc.). Cette entité permet de séparer les données descriptives du joueur de ses données statistiques.

— **Match** : représente une rencontre de football. Un match relie deux équipes, appartient à une ligue ou une compétition, et contient des informations telles que le score, la date et le résultat.

Ces entités distinctes permet une modélisation claire, évolutive et conforme à la réalité du football moderne.

3.2 Relations du graphe

Les relations constituent un élément central du modèle orienté graphe, car elles permettent de représenter les interactions entre les différentes entités. Dans ce modèle, chaque relation possède une signification précise et reflète une interaction réelle du domaine footballistique.

Les relations principales du graphe sont :

— **(Club)-[:PLAYS_IN]->(League)** : indique qu'un club évolue dans un championnat national donné.

— **(Club)-[:PARTICIPATES_IN]->(Competition)** : représente la participation d'un club à une ou plusieurs compétitions nationales ou internationales.
— **(Player)-[:PLAYS_FOR]->(Club)** : relie un joueur au club auquel il appartient durant la saison analysée.
— **(Player)-[:HAS_ADVANCED_STATS]->(PlayerStats)** : associe un joueur à ses statistiques avancées pour une saison donnée.
— **(Club)-[:PLAYED_HOME]->(Match)** : indique qu'un club a disputé un match en tant qu'équipe à domicile.
— **(Club)-[:PLAYED_AWAY]->(Match)** : indique qu'un club a disputé un match en tant qu'équipe à l'extérieur.
— **(Match)-[:IN_LEAGUE]->(League)** : relie un match de championnat à la ligue correspondante.
— **(Match)-[:IN_COMPETITION]->(Competition)** : relie un match à une compétition spécifique.

L'ensemble de ces relations permet une navigation fluide à travers le graphe et facilite la formulation de requêtes analytiques complexes, telles que l'analyse des performances par ligue, par club ou par joueur.

3.3 Modèle visuel

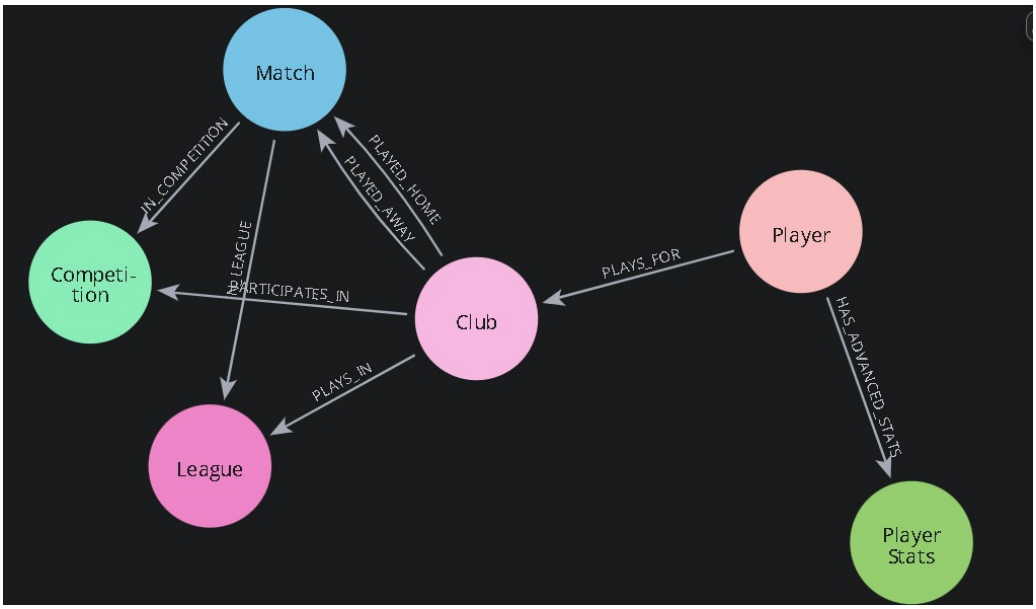


FIGURE 3.1 – Modèle de données orienté graphe

Pour ce premier file, nous avons plus de 120 proprietes, separés sur deux entités player et player stats 2689 lignes

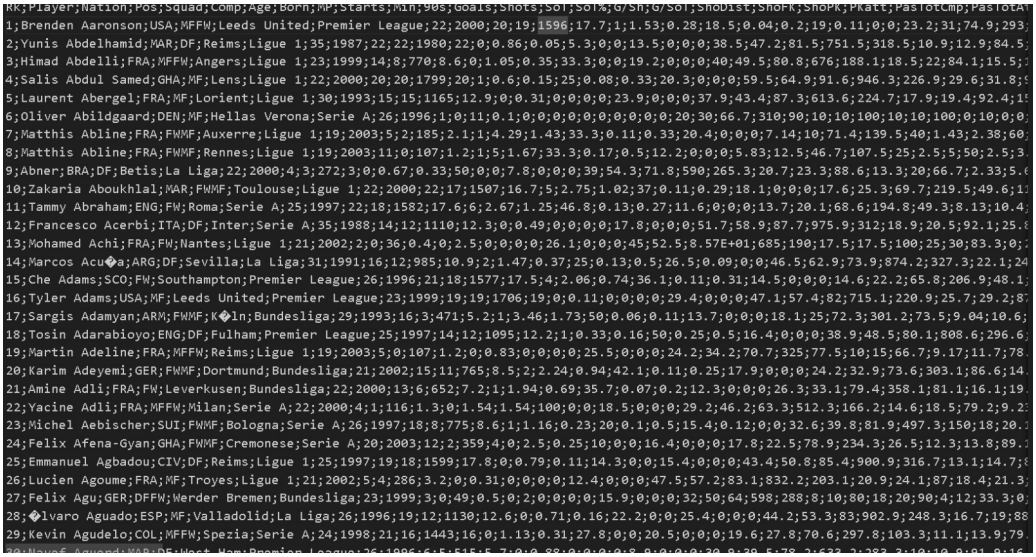
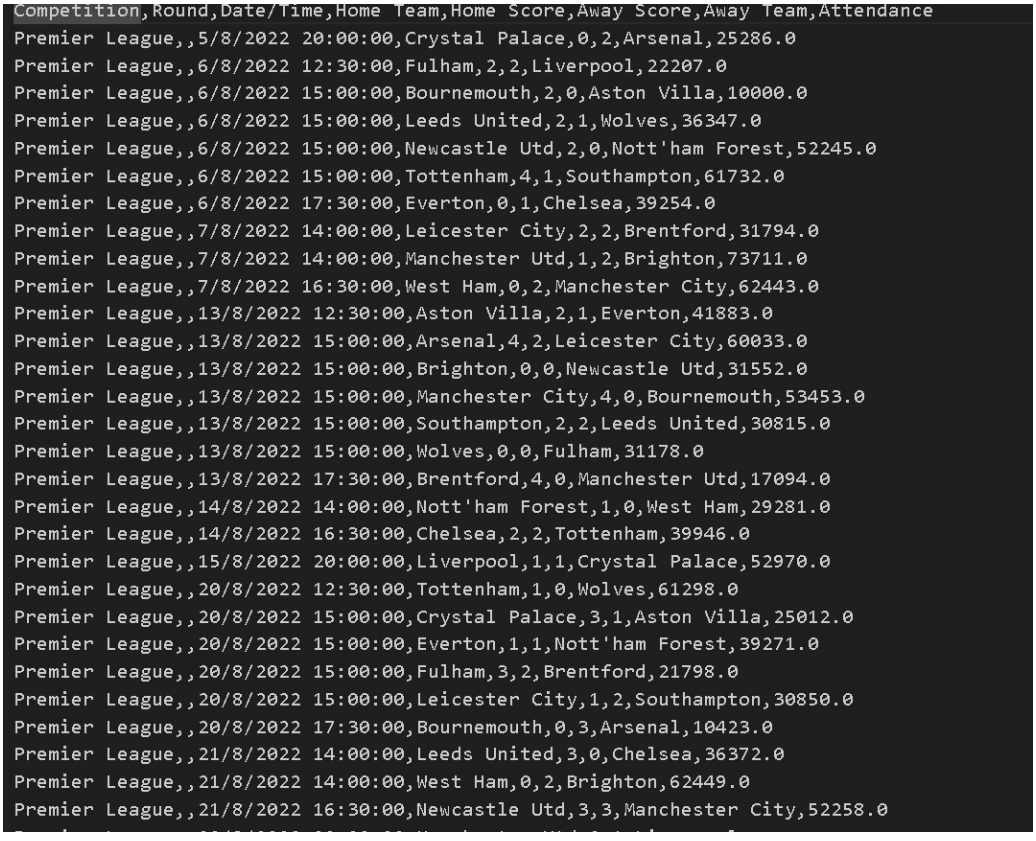


FIGURE 3.2 – file des données de joueurs

Ici nous avons des fichiers des matchs 8 proprietes et 3516 lignes



```
Competition,Round,Date/Time,Home Team,Home Score,Away Score,Away Team,Attendance
Premier League,,5/8/2022 20:00:00,Crystal Palace,0,2,Arsenal,25286.0
Premier League,,6/8/2022 12:30:00,Fulham,2,2,Liverpool,22207.0
Premier League,,6/8/2022 15:00:00,Bournemouth,2,0,Aston Villa,10000.0
Premier League,,6/8/2022 15:00:00,Leeds United,2,1,Wolves,36347.0
Premier League,,6/8/2022 15:00:00,Newcastle Utd,2,0,Nott'ham Forest,52245.0
Premier League,,6/8/2022 15:00:00,Tottenham,4,1,Southampton,61732.0
Premier League,,6/8/2022 17:30:00,Everton,0,1,Chelsea,39254.0
Premier League,,7/8/2022 14:00:00,Leicester City,2,2,Brentford,31794.0
Premier League,,7/8/2022 14:00:00,Manchester Utd,1,2,Brighton,73711.0
Premier League,,7/8/2022 16:30:00,West Ham,0,2,Manchester City,62443.0
Premier League,,13/8/2022 12:30:00,Aston Villa,2,1,Everton,41883.0
Premier League,,13/8/2022 15:00:00,Arsenal,4,2,Leicester City,60033.0
Premier League,,13/8/2022 15:00:00,Brighton,0,0,Newcastle Utd,31552.0
Premier League,,13/8/2022 15:00:00,Manchester City,4,0,Bournemouth,53453.0
Premier League,,13/8/2022 15:00:00,Southampton,2,2,Leeds United,30815.0
Premier League,,13/8/2022 15:00:00,Wolves,0,0,Fulham,31178.0
Premier League,,13/8/2022 17:30:00,Brentford,4,0,Manchester Utd,17094.0
Premier League,,14/8/2022 14:00:00,Nott'ham Forest,1,0,West Ham,29281.0
Premier League,,14/8/2022 16:30:00,Chelsea,2,2,Tottenham,39946.0
Premier League,,15/8/2022 20:00:00,Liverpool,1,1,Crystal Palace,52970.0
Premier League,,20/8/2022 12:30:00,Tottenham,1,0,Wolves,61298.0
Premier League,,20/8/2022 15:00:00,Crystal Palace,3,1,Aston Villa,25012.0
Premier League,,20/8/2022 15:00:00,Everton,1,1,Nott'ham Forest,39271.0
Premier League,,20/8/2022 15:00:00,Fulham,3,2,Brentford,21798.0
Premier League,,20/8/2022 15:00:00,Leicester City,1,2,Southampton,30850.0
Premier League,,20/8/2022 17:30:00,Bournemouth,0,3,Arsenal,10423.0
Premier League,,21/8/2022 14:00:00,Leeds United,3,0,Chelsea,36372.0
Premier League,,21/8/2022 14:00:00,West Ham,0,2,Brighton,62449.0
Premier League,,21/8/2022 16:30:00,Newcastle Utd,3,3,Manchester City,52258.0
```

FIGURE 3.3 – file des matchs

Chapitre 4

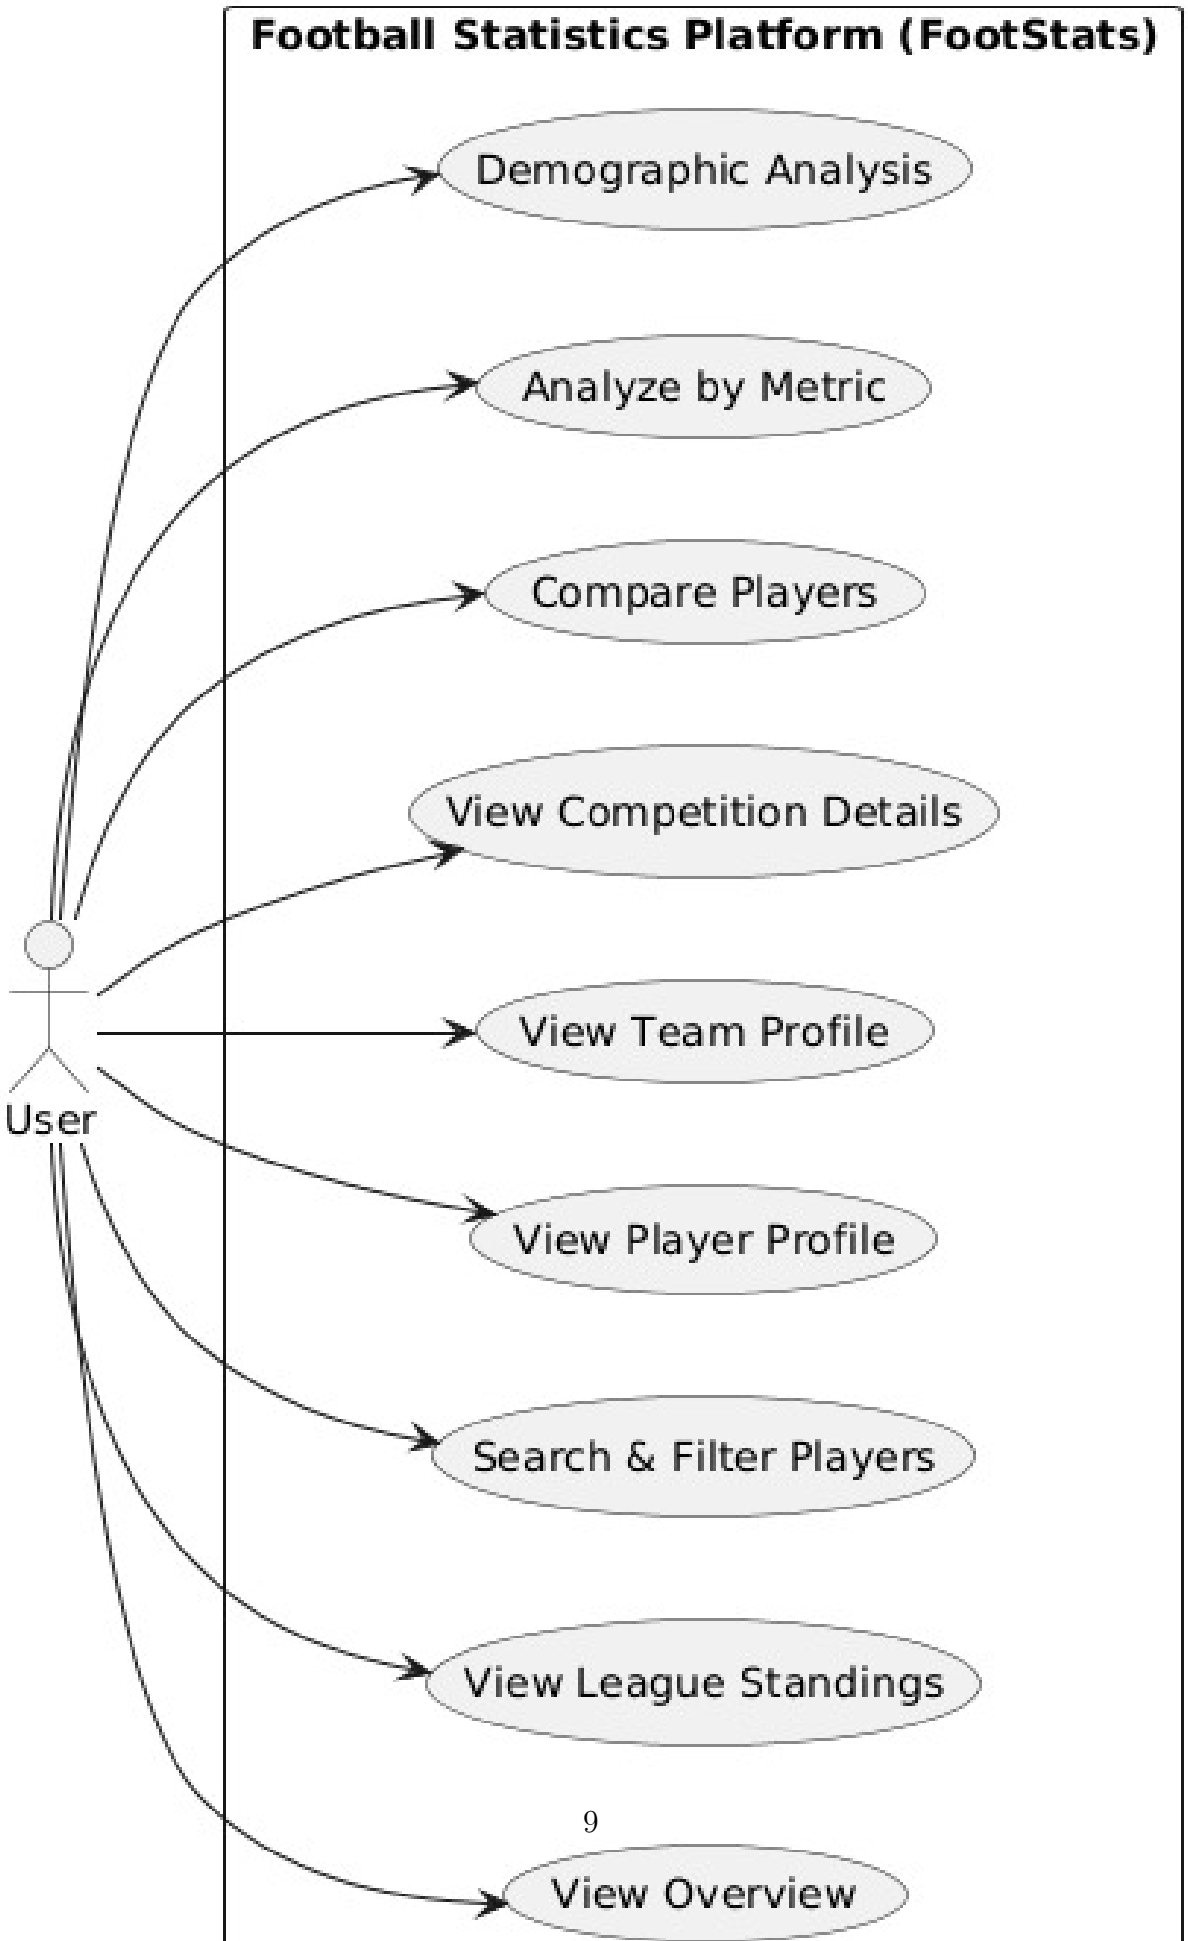
Implémentation de l'application analytique

Ce chapitre présente l'implémentation de l'application analytique développée dans le cadre de ce projet. Il décrit les principales interfaces de l'application ainsi que leur rôle.

Chaque interface correspond à un ensemble de fonctionnalités analytiques spécifiques, permettant à l'utilisateur d'interagir avec le graphe, de visualiser les données et d'exécuter des requêtes Neo4j de manière transparente. Les principales requêtes Cypher utilisées sont également présentées afin d'illustrer concrètement l'exploitation du modèle orienté graphe et de justifier les résultats affichés dans l'application.

L'objectif de ce chapitre est ainsi de montrer comment les choix de modélisation et les requêtes Neo4j sont traduits en une application analytique cohérente.

4.1 Diagramme de cas d'utilisation



4.2 Page d'accueil : Dashboard global

La page d'accueil offre une vision synthétique du football européen : meilleurs buteurs, passeurs, classements et matchs récents.

figure

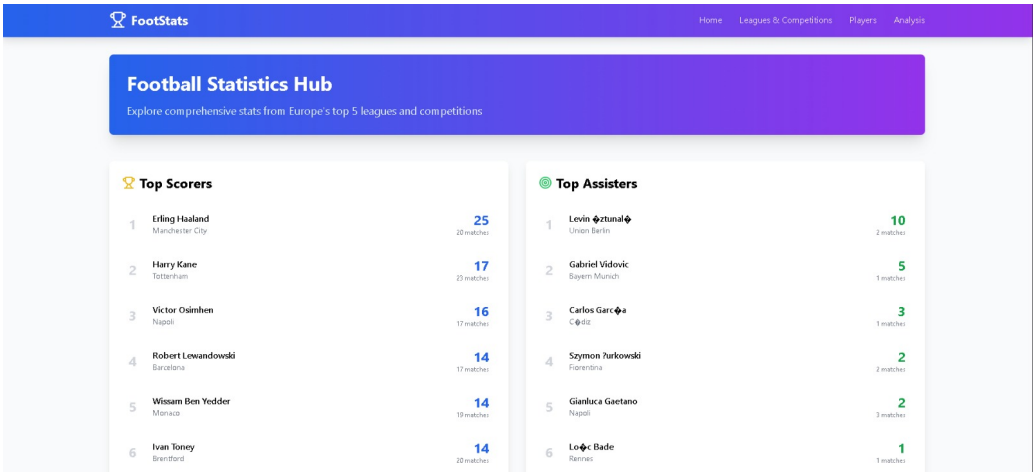


FIGURE 4.2 – Dashboard global

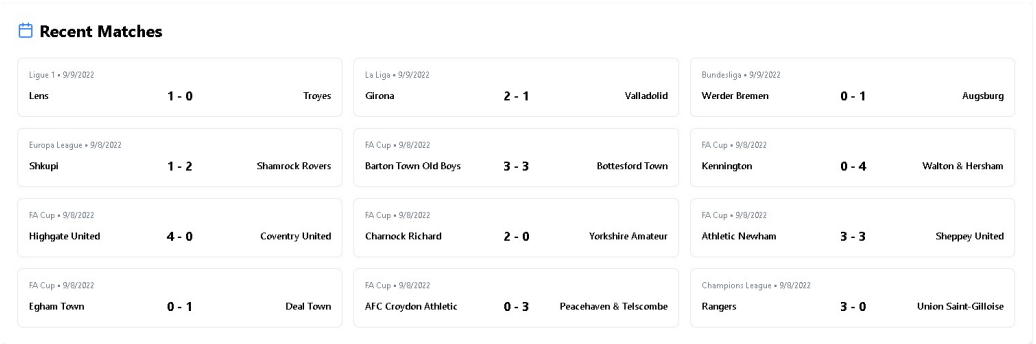


FIGURE 4.3 – Matchs récents

4.3 Page Ligues et Compétitions

Cette interface nous montre les 5 plus grandes ligues Européennes, ainsi que différentes compétitions Européennes tels que la Champions League,Europa League,Europa Conference League, la FA Cup

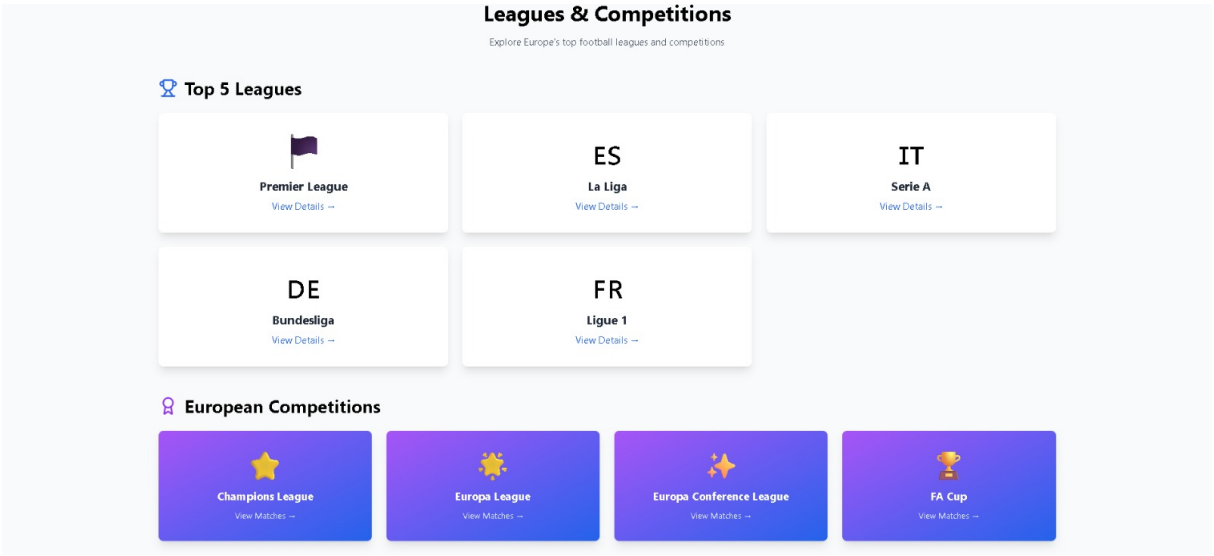
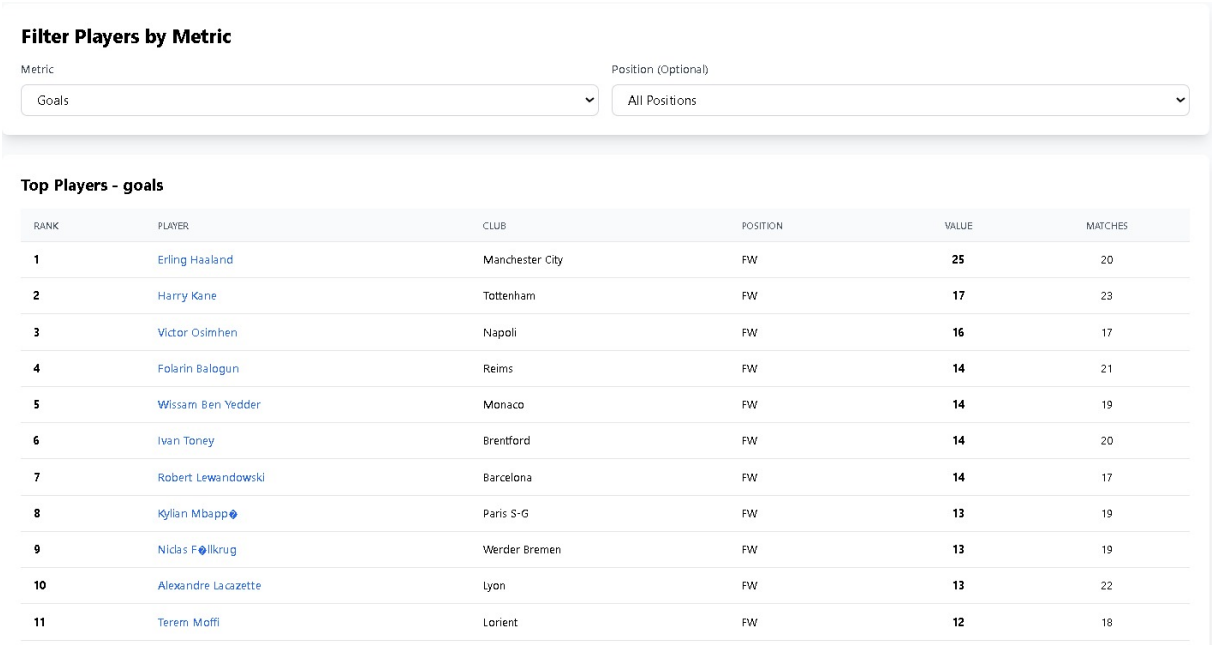


FIGURE 4.4 – Ligues et compétitions

4.3.1 Statistiques globales d'une ligue

Requête Cypher utilisée :

```
MATCH (m:Match)-[:IN_LEAGUE]->(l:League {name:'Premier League'})
RETURN count(m) AS matches,
       sum(m.total_goals) AS goals,
       avg(m.total_goals) AS avg_goals
```



RANK	PLAYER	CLUB	POSITION	VALUE	MATCHES
1	Erling Haaland	Manchester City	FW	25	20
2	Harry Kane	Tottenham	FW	17	23
3	Victor Osimhen	Napoli	FW	16	17
4	Folarin Balogun	Reims	FW	14	21
5	Wissam Ben Yedder	Monaco	FW	14	19
6	Ivan Toney	Brentford	FW	14	20
7	Robert Lewandowski	Barcelona	FW	14	17
8	Kylian Mbapp	Paris S-G	FW	13	19
9	Niclas F|llkrug	Werder Bremen	FW	13	19
10	Alexandre Lacazette	Lyon	FW	13	22
11	Terem Moffi	Lorient	FW	12	18

FIGURE 4.5 – Statistique par métrique



FIGURE 4.6 – Statistiques par Position et par A

4.4 Page Joueurs

Cette page nous donne des informations telles que le poste , la nationalité , l'age et le club dans lequel il évolue. Nous pouvons effectuer des filtres de joueurs grace à cette page selon les caractéristiques voulues.

Requete Cypher utilisée

```
MATCH (p:Player)-[:PLAYS_FOR]->(c:Club)
WHERE p.position = $position
RETURN p.name, p.age, c.name
```

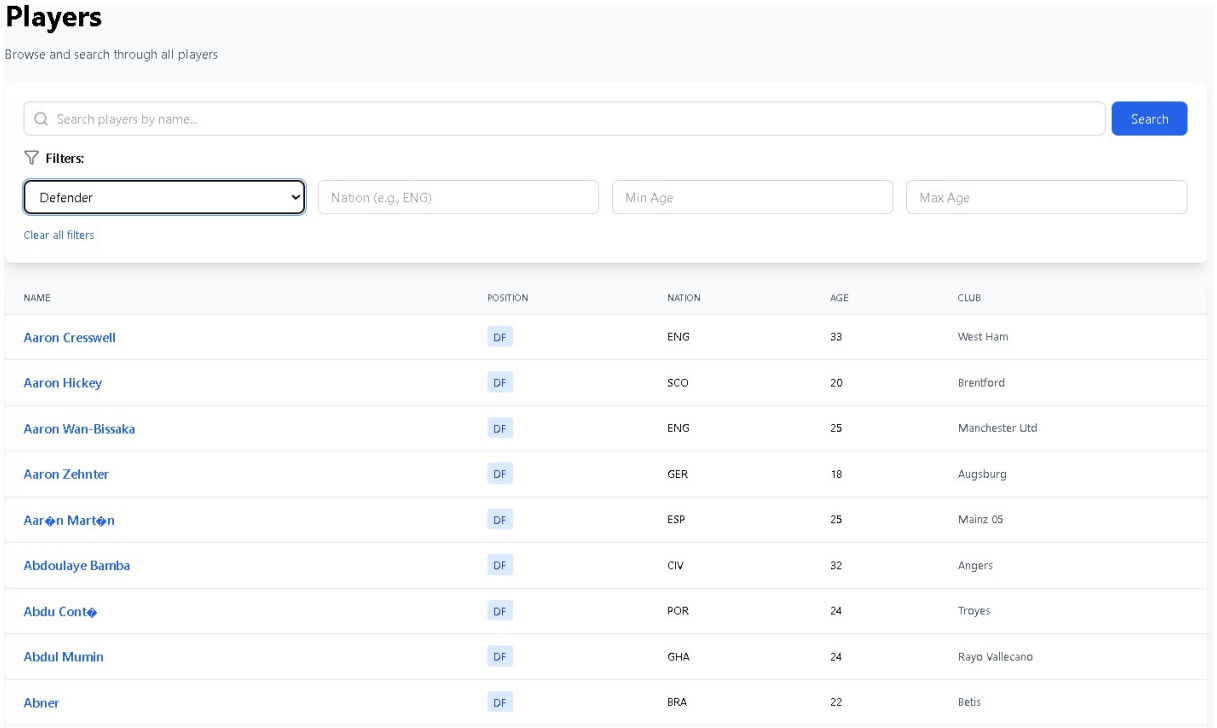


FIGURE 4.7 – Recherche et filtrage des joueurs

4.5 Comparaison entre joueurs

L'interface représente la comparaison entre deux jouers distincts.

```
MATCH (p1:Player {name:$p1})-[:HAS_ADVANCED_STATS]->(s1)
MATCH (p2:Player {name:$p2})-[:HAS_ADVANCED_STATS]->(s2)
RETURN p1.name, s1.goals, p2.name, s2.goals
```

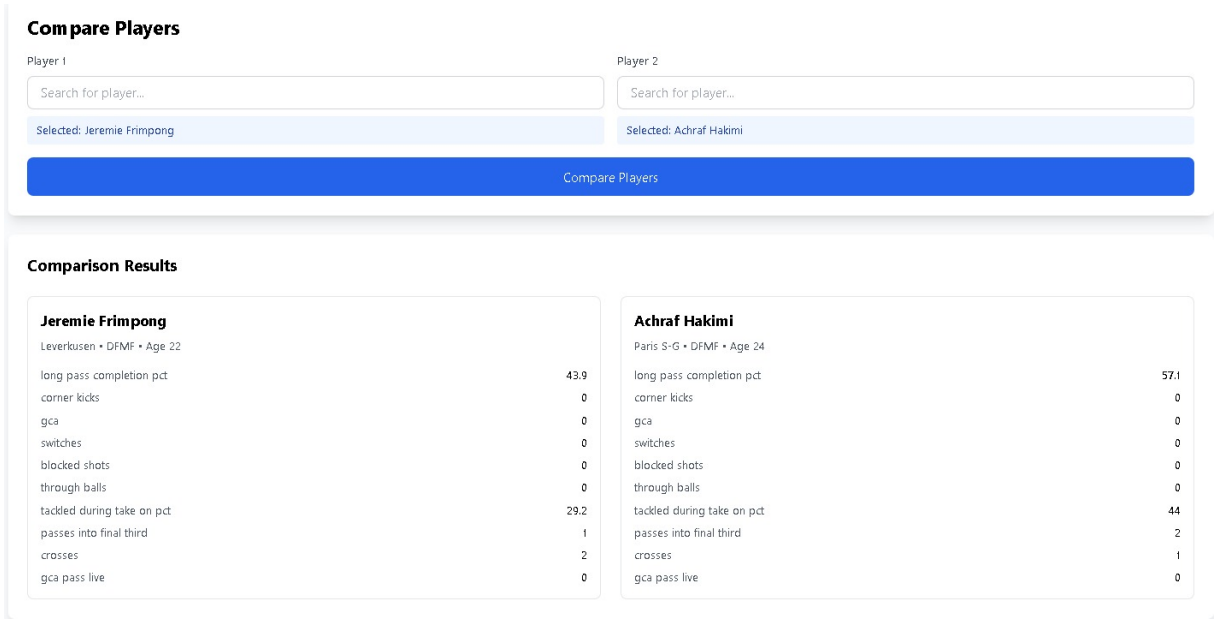


FIGURE 4.8 – Comparaison de joueurs

4.6 Page détail Club

Cette page de l'application regroupe toutes les informations concernant un club.

Requete Cypher utilisée

```
MATCH (p:Player)-[:PLAYS_FOR]->(c:Club {name:'Arsenal'})
RETURN p.name, p.position, p.age, p.nation
ORDER BY p.position
```



FIGURE 4.9 – Détail d'un club

Ici on voit les meilleurs buteurs du club qui a été choisi.

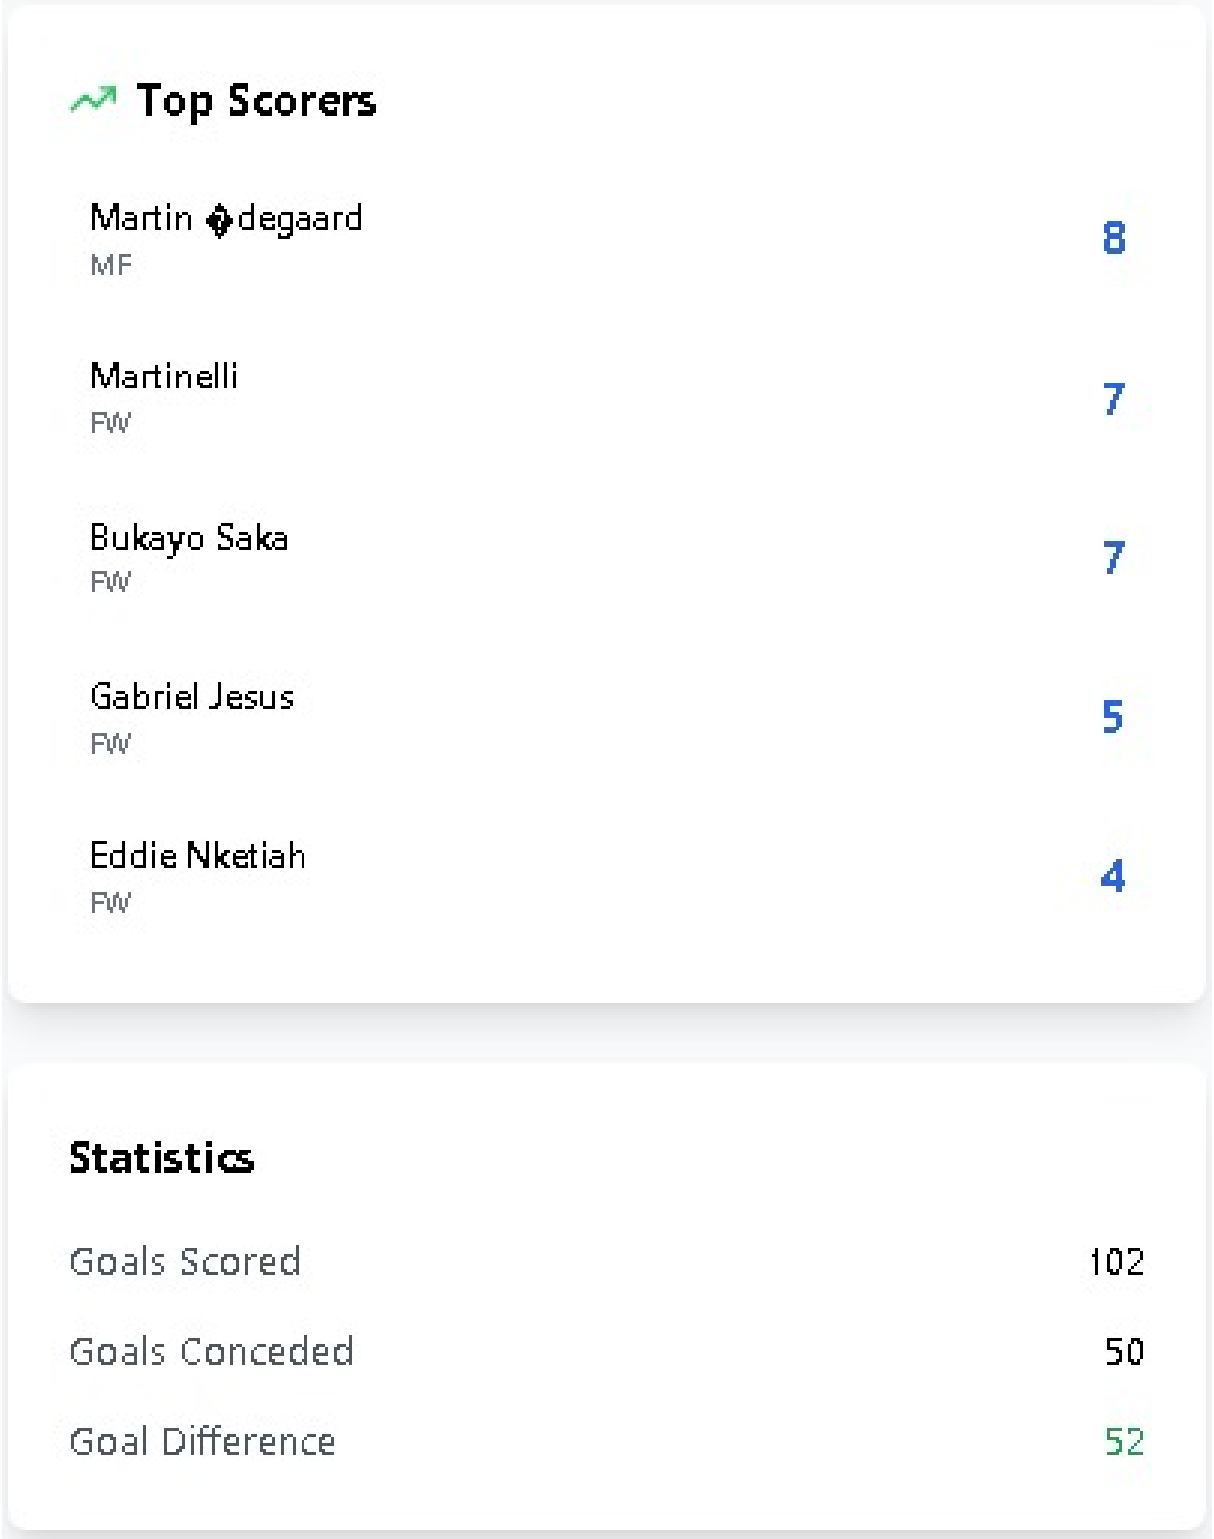


FIGURE 4.10 – Détail d'un club

Cette page nous montre l'effectif complet du club, en definissant les postes,nationalités et ages des joueurs.

Squad

NAME	POSITION	NATION	AGE
Ben White	DF	ENG	25
C�dric Soares	DF	POR	31
Gabriel Dos Santos	DF	BRA	25
Kieran Tierney	DF	SCO	25
Oleksandr Zinchenko	DF	UKR	26
Rob Holding	DF	ENG	27
Takehiro Tomiyasu	DF	JPN	24
William Saliba	DF	FRA	21
Bukayo Saka	FW	ENG	21
Eddie Nketiah	FW	ENG	23
Ethan Nwaneri	FW	ENG	15
Gabriel Jesus	FW	BRA	25
Leandro Trossard	FW	BEL	28
Martinelli	FW	BRA	21
Reiss Nelson	FW	ENG	23
Aaron Ramsdale	GK	ENG	24
Albert Sambi Lokonga	MF	BEL	23
Granit Xhaka	MF	SUI	30

FIGURE 4.11 – Détail d'un club

Chapitre 5

Limites et perspectives

5.1 Limites

Malgré les résultats obtenus, ce projet présente certaines limites qu'il convient de souligner. Tout d'abord, les données exploitées sont limitées à une seule saison sportive, ce qui restreint les possibilités d'analyse temporelle et empêche l'étude de l'évolution des performances sur plusieurs saisons.

Par ailleurs, certaines équipes présentes dans les matchs, notamment celles issues de divisions inférieures ou des tours préliminaires de certaines compétitions, ne sont pas modélisées comme des nœuds (club) complets dans la base de données. Dans ces cas, les informations sont conservées sous forme de propriétés textuelles au niveau des matchs, ce qui limite les analyses relationnelles impliquant ces équipes.

Enfin, l'application développée se concentre principalement sur des analyses descriptives et exploratoires. Elle ne propose pas encore de fonctionnalités d'analyse prédictive ou de modélisation avancée permettant, par exemple, d'anticiper les performances futures des joueurs ou des équipes. Ces limitations ouvrent toutefois des perspectives d'amélioration et d'extension du système.

5.2 Perspectives

Les limites identifiées dans ce projet ouvrent naturellement la voie à plusieurs perspectives d'évolution et d'amélioration. Une première extension consisterait à intégrer des données couvrant plusieurs saisons sportives. Une telle évolution permettrait de réaliser des analyses temporelles plus approfondies, d'étudier l'évolution des performances des joueurs et des clubs, et d'identifier des tendances à long terme.

Une autre perspective importante serait l'enrichissement du modèle de données afin de représenter de manière plus efficace l'ensemble des équipes présentes dans les compétitions, y compris celles issues de divisions inférieures ou de phases préliminaires. Cela renforcerait la cohérence du graphe et permettrait des analyses relationnelles encore plus complètes.

Sur le plan analytique, le projet pourrait évoluer vers l'intégration de techniques d'analyse prédictive et de machine learning. En s'appuyant sur les données historiques stockées dans le graphe, il serait possible de prédire certaines performances futures, telles que le rendement d'un joueur, les résultats probables d'un match ou l'évolution d'un classement. L'association de Neo4j avec des bibliothèques d'analyse avancée en Python offrirait un cadre particulièrement adapté à ce type de développements.

Enfin, l'application web pourrait être améliorée en proposant des visualisations interactives plus avancées, des tableaux de bord personnalisables et des fonctionnalités d'aide à la décision destinées aux analystes sportifs, aux recruteurs ou aux entraîneurs. Ces évolutions permettraient de transformer l'application en un véritable outil d'analyse décisionnelle.

Chapitre 6

Conclusion

Ce projet démontre de manière concrète la pertinence des bases de données orientées graphe dans l'analyse de données footballistiques complexes et fortement interconnectées. L'utilisation de Neo4j a permis de mettre en place une modélisation naturelle et fidèle à la réalité du football professionnel, où les relations entre entités jouent un rôle central dans l'analyse des performances.

Grâce au langage de requête Cypher, les données ont pu être exploitées à travers des requêtes expressives et lisibles ce qui facilite l'exploration relationnelle et la réalisation d'analyses avancées. L'application développée illustre ainsi l'intérêt d'une architecture combinant une base de données graphe, un backend analytique et une interface web interactive pour transformer des données complexes en informations exploitables.

En définitive, ce travail constitue une base solide pour le développement d'outils d'analyse sportive modernes, évolutifs et orientés décision, et met en évidence le potentiel du paradigme graphe dans des domaines où la donnée relationnelle est au cœur des enjeux analytiques.